

Personality Type Predictor

Executive Summary der Machine Learning Projektabgabe

Cem Karakiz | Stand 1. Oktober 2026

Ergebnis auf einen Blick

Eine reproduzierbare Mehrklassen-Klassifikation verarbeitet 19 Frageantworten sowie age, gender und hand. Die abgestimmte logistische Regression wurde anhand des höheren Macro-F1-Werts als Champion ausgewählt, in MLflow dokumentiert und als vollständige Pipeline in einer Streamlit-App nutzbar gemacht.

Kennzahl	Ergebnis
Champion	Logistische Regression
CV-F1-Macro	0,7683
Test-Accuracy	0,8471
Test-F1-Macro	0,7545

Problem und Daten

Die Zielvariable target enthält vier Klassen: Moderate, Resilient, Overcontroller und Undercontroller. Das Codebook nennt zusätzlich Reserved, diese Klasse fehlt jedoch in der CSV. Der Rohdatensatz enthält 19.719 Zeilen und 23 Spalten; die Klassen sind unterschiedlich groß.

Datenproblem	Entscheidung
Eine Zeile mit 19 ungültigen Null-Antworten	Zeile entfernt
82 Alterswerte über 120	Als fehlend markiert
24 fehlende gender und 100 fehlende hand	In Pipeline als Unknown

Ergebnis der Bereinigung: 19.718 Zeilen. Die Rohdatei bleibt unverändert; data_processed.csv wird reproduzierbar erzeugt.

Lösungspfad

- 1. EDA prüft Datenqualität, dokumentiert Entscheidungen und speichert die bereinigte Datei.
- 2. Stratified Train-Test-Split hält 20 Prozent bis zur finalen Bewertung zurück.
- 3. Numerische Pipeline: Median-Imputation und StandardScaler.
- 4. Kategorische Pipeline: Unknown-Imputation und OneHotEncoder.
- 5. Fünffache Kreuzvalidierung und GridSearchCV vergleichen beide Modellkandidaten.
- 6. MLflow speichert Parameter, Metriken und vollständige Pipelines; Streamlit lädt den Champion.

Modellvergleich und Auswahl

Macro-F1 ist die primäre Auswahlmetrik, weil jede Klasse gleichgewichtet wird. Die Testdaten beeinflussen weder Modellwahl noch Hyperparameterabstimmung.

Modell	Beste Einstellung	CV-F1-Macro
Logistische Regression	C = 10,0	0,7683
Random Forest	max_depth = None	0,7453

Die logistische Regression liegt vorn und wird vor der einmaligen Testbewertung als Champion festgelegt. Die dokumentierte Hauptprojekt-Run-ID lautet 8fc4677111f24798aac65c1cac66c5ab; der Run trägt den Tag selection = champion.

Wichtige Entscheidungen

- **Unknown statt häufigster Kategorie:** vermeidet eine unbelegte Zuschreibung bei fehlenden Angaben.
- **Pipeline statt manueller Vorverarbeitung:** wendet identische Schritte in Training, Validierung und App an.
- **Macro-F1 statt nur Accuracy:** berücksichtigt alle Klassen gleichgewichtet.
- **Keine weitere Feinsuche:** die Verbesserung der logistischen Regression beträgt nur rund 0,0008.

MLflow, App und Reproduzierbarkeit

Die App bietet alle 22 Eingaben an, sucht automatisch den neuesten als champion markierten Run und lädt dessen vollständige Pipeline über die aktuelle Run-ID. Ein Clean-Clone-Test bestätigte Installation, EDA, Modeling, neue MLflow-Runs und eine reale Streamlit-Vorhersage ohne Fehler.

Limitationen

- Die Zielvariable wurde aus Frageantworten abgeleitet, die zugleich Modelleingaben sind.
- Es fehlt eine externe Validierung mit unabhängigen Daten.
- Reserved steht im Codebook, kommt aber nicht in der CSV vor.
- Die Vorhersage ist keine psychologische oder medizinische Diagnose.

Empfehlung

Vor einer fachlichen Nutzung sollte das Modell extern validiert und die fehlende Klasse Reserved geklärt werden. Weitere Modelle sind nur sinnvoll, wenn sie eine konkrete offene Entscheidung adressieren. Für die Projektabgabe bilden die dokumentierte Pipeline, MLflow-Evidence, funktionierende App und bestätigte Reproduzierbarkeit einen vollständigen Nachweis des Workflows.